Nome da Equipe: ***QInvest***

Integrantes:

Alexandre Barbosa de Almeida
Cainã Pessoa
Cairo Henrique Vaz Cotrim
Élen Silva Almeida
José de Anchieta C C Netto
Júlio César Reis da Silva
Leandro Luiz de Lima Freitas
Leonardo Alves Santana
Matheus Albert Oliveira dos Santos
Michel Pereira da Cunha

Problema Escolhido: ***O Problema da Mochila (Knapsack)***

Algoritmo Escolhido: ***VQE (Variational Quantum Eigensolver)***

ETAPA 1 - PESQUISA

Link COLAB: VQE_Knapsack_QInvest.ipynb

Q1: Como o algoritmo funciona?

O *Variational Quantum Eigensolver* (VQE) é um algoritmo híbrido que combina computação quântica e otimização clássica para estimar a energia do estado fundamental de um sistema quântico. Seu funcionamento baseia-se no princípio variacional da mecânica quântica, que estabelece que o valor esperado da energia de um estado quântico aproximado nunca pode ser menor que a energia do estado fundamental do sistema [1].
Matematicamente, esse princípio pode ser expresso por: $E(\theta) = \langle\psi(\theta)|H|\psi(\theta)\rangle \geq E$, onde H representa o Hamiltoniano do sistema, $|\psi(\theta)\rangle$ é o estado quântico parametrizado preparado por um circuito quântico, θ representa os parâmetros variacionais do circuito e $E0$ é a energia do estado fundamental. O algoritmo começa definindo um circuito quântico parametrizado, chamado *Ansatz*, que gera um estado quântico candidato. Esse circuito é executado em um computador quântico, onde são realizadas medições para estimar o valor esperado do Hamiltoniano. Em seguida, um algoritmo de otimização clássico ajusta os parâmetros do circuito com o objetivo de minimizar a energia calculada. Devido à desigualdade acima, minimizar a média energética implica na aproximação da energia fundamental. Esse processo é repetido iterativamente até que o valor da energia seja pequeno o suficiente, ou seja, próximo da energia do estado fundamental do sistema [1][2].

Q2: Para que tipo de problemas ele foi desenvolvido?

O VQE foi desenvolvido principalmente para resolver problemas de autovalor mínimo de Hamiltonianos quânticos, ou seja, determinar a energia do estado fundamental de sistemas quânticos. Esse tipo de problema é central em áreas como química quântica computacional, física da matéria condensada e ciência dos materiais, pois a energia mínima do sistema está diretamente relacionada às propriedades físicas e químicas desses sistemas [1][2]. Uma aplicação importante do VQE é o cálculo da estrutura eletrônica de moléculas, permitindo estimar propriedades como energia de ligação e estabilidade molecular. Na literatura científica, moléculas simples como H_2, LiH e BeH_2 são frequentemente utilizadas como sistemas de teste para avaliar o desempenho do algoritmo [1][3]. Além dessas aplicações, problemas de otimização combinatória também podem ser reformulados como problemas de minimização de Hamiltonianos, permitindo a aplicação de algoritmos variacionais em áreas como finanças quantitativas. Nesse contexto, técnicas inspiradas no VQE podem ser utilizadas em problemas como otimização de portfólio, alocação de ativos e gestão de risco, onde o objetivo é minimizar funções de custo associadas ao risco e ao retorno de investimentos [3].

Q3: Quais são as suas principais limitações?

Apesar de seu potencial, o VQE apresenta algumas limitações importantes. Uma das principais está relacionada às restrições do hardware quântico atual, que sofre com ruído, erros de medição e limitações na profundidade dos circuitos devido à decoerência [2]. Outra dificuldade envolve a escalabilidade do algoritmo, já que o número de termos na decomposição do Hamiltoniano cresce rapidamente com o tamanho do sistema, aumentando o número de medições necessárias e o custo computacional. Além disso, a escolha do ansatz representa um desafio, pois circuitos pouco expressivos podem impedir a convergência correta, enquanto circuitos mais complexos tornam-se mais sensíveis ao ruído [3]. Por fim, o processo de otimização clássica pode ser afetado pelo fenômeno conhecido como barren plateaus, no qual os gradientes da função custo tornam-se extremamente pequenos à medida que o número de qubits aumenta, dificultando a convergência do algoritmo [3].

ETAPA 2 - IMPLEMENTAÇÃO E ANÁLISE

Q1 — Quais foram os desafios para implementar esse algoritmo?

A implementação do algoritmo *Variational Quantum Eigensolver* (VQE) aplicada ao problema da Mochila apresentou alguns desafios conceituais e técnicos ao longo do desenvolvimento do projeto. Primeiramente, como o VQE opera sobre Hamiltonianos, foi necessário converter o problema original em uma formulação do tipo QUBO (*Quadratic Unconstrained Binary Optimizatio*n), incorporando os termos matemáticos em *loops for*. Também foi necessário utilizar variáveis de folga para representar adequadamente as restrições do problema, o que exigiu um entendimento mais aprofundado sobre a construção dos termos QUBO.

Outro desafio importante foi a transformação das variáveis binárias do modelo QUBO para matrizes de Pauli adequadas à formulação quântica. A construção correta do Hamiltoniano, contendo termos envolvendo operadores Z_i e $Z_i Z_{,j}$ exigiu atenção na implementação para garantir que os coeficientes e operadores fossem representados corretamente em Python.

Além disso, a escolha do ansatz variacional e do otimizador clássico representou um dos desafios mais relevantes. Como o VQE é um algoritmo híbrido, seu desempenho depende diretamente do processo de otimização clássica responsável por ajustar os parâmetros do circuito. Durante os testes iniciais, alguns otimizadores apresentaram dificuldade em convergir para boas soluções, frequentemente ficando presos em mínimos locais. Ao mesmo tempo, a estrutura do ansatz também precisou ser ajustada para garantir que o circuito tivesse expressividade suficiente para representar estados quânticos próximos da solução ótima.

Q2 — Que ajustes foram feitos? E quais mudanças nos resultados foram observadas?

Durante o desenvolvimento e os experimentos realizados pelo grupo, foram feitos diversos ajustes nos parâmetros e na estrutura do algoritmo com o objetivo de melhorar a qualidade das soluções encontradas pelo VQE. Um dos principais ajustes foi a escolha do otimizador clássico, que inicialmente apresentou dificuldades de convergência. Após testes com diferentes abordagens, o otimizador foi substituído pelo SPSA (*Simultaneous Perturbation Stochastic Approximation*), que se mostrou mais robusto para a otimização.

Outro ajuste importante envolveu melhorias no ansatz variacional e no valor de penalidade, permitindo uma exploração mais eficiente do espaço de soluções. Também foram realizados ajustes na forma de modelar a restrição do problema da mochila. Inicialmente, a restrição de capacidade foi implementada como uma igualdade $(= W)$, mas posteriormente foi reformulada como uma desigualdade $(\leq W)$, tornando o modelo mais fiel à definição clássica do problema.

Durante os testes, também foi observado que o autoestado com maior probabilidade após as medições nem sempre correspondia à melhor solução. Para lidar com essa situação, o processo de atualização das camadas do ansatz passou a considerar o autoestado com menor energia estimada, obtido a partir da análise das medições dos diferentes estados possíveis. Antes dessas modificações, o VQE frequentemente convergia para um mínimo local com valor total da mochila igual a 25. Após os ajustes implementados, o algoritmo passou a encontrar consistentemente a solução ótima de valor 32. Os resultados também mostraram um aumento na probabilidade associada às melhores bitstrings, algo que pode ser observado no heatmap gerado no código.

Q3 — Que outros ajustes ou melhorias poderiam ter sido feitos?

Embora a implementação realizada tenha conseguido reproduzir corretamente a solução ótima do problema estudado, existem algumas melhorias que poderiam ser exploradas para aprimorar os resultados e aprofundar a análise do algoritmo. Uma possibilidade seria realizar uma exploração mais ampla do espaço de hiperparâmetros, incluindo diferentes profundidades do ansatz, números de camadas, configurações do otimizador e limites de interação. Além disso, seria possível utilizar outras técnicas sistemáticas de busca de hiperparâmetros, como o gradiente descendente, para identificar melhor as combinações que produzem melhores resultados.

Outra melhoria possível seria testar diferentes estruturas de ansatz variacional. No trabalho realizado foi utilizado um ansatz relativamente simples e eficiente para hardware atual, porém existem alternativas que podem apresentar melhor desempenho para determinados tipos de problema, como ansätze inspirados na estrutura do próprio problema ou métodos adaptativos que constroem o circuito de forma incremental. Essas abordagens podem reduzir o número de parâmetros necessários e melhorar a eficiência da otimização.

Também seria interessante testar instâncias maiores do Problema da Mochila ou de outros problemas de otimização combinatória, permitindo avaliar melhor a escalabilidade do VQE. Por fim, uma extensão relevante do trabalho seria executar o algoritmo em hardware quântico real, e não apenas em simuladores. Isso permitiria analisar o impacto de fatores como ruído, erros de medição e decoerência, oferecendo uma avaliação mais completa do desempenho do VQE em cenários práticos.

REFERÊNCIAS

1. Scursulim, J.V.S., Langeloh, G.M., Beltran, V.L. *et al.* Multiclass portfolio optimization via variational quantum Eigensolver with Dicke state ansatz. *Sci Rep* 16, 6208 (2026). https://doi.org/10.1038/s41598-026-36333-4
2. McClean, J. R., Romero, J., Babbush, R., & Aspuru-Guzik, A. (2016).*The theory of variational hybrid quantum-classical algorithms*. New Journal of Physics, 18(2), 023023. https://doi.org/10.1088/1367-2630/18/2/023023
3. Cerezo, M. *et al*. (2021). *Variational quantum algorithms*. Nature Reviews Physics, 3, 625–644. https://doi.org/10.1038/s42254-021-00348-9