Nome da Equipe: ***QInvest***
Integrantes:
Alexandre Barbosa de Almeida
Cairo Henrique Vaz Cotrim
Élen Silva Almeida
José de Anchieta C C Netto
Júlio César Reis da Silva
Leonardo Alves Santana
Matheus Albert Oliveira dos Santos
Michel Pereira da Cunha
Problema Escolhido: ***Otimização de Portfólio Financeiro***
Algoritmo Escolhido: ***VQE (Variational Quantum Eigensolver)***
Link Colab: Grupo11_VQE_Portfolio_Optimization.ipynb

1. PROBLEMA E SOLUÇÃO ESCOLHIDOS

O projeto aborda um dos problemas mais clássicos e fundamentais das finanças quantitativas: a Otimização de Portfólio. O foco é a seleção de ativos em renda variável, utilizando um subconjunto de ações do índice norte-americano ***S&P 500***. O objetivo central do problema é escolher uma combinação de ativos que maximize o retorno esperado do investimento e, simultaneamente, minimize o risco (volatilidade ou CVaR) sob certas condições de restrição (por exemplo, *budget* fixo), em concordância direta com os fundamentos da **Teoria Moderna de Portfólio**, de **Harry Markowitz**.

A fim de adequar o problema às limitações da computação quântica atual, o portfólio foi inicialmente formulado como um problema binário, no qual cada ativo é representado por um qubit, assumindo valor 1 quando selecionado e 0 caso contrário. Essa abordagem permite modelar a seleção de ativos como um problema **QUBO (*Quadratic Unconstrained Binary Optimization*)**, compatível com algoritmos variacionais como o **VQE (*Variational Quantum Eigensolver*)**. Em seguida, os resultados obtidos foram comparados com a solução clássica baseada na Teoria Moderna do Portfólio, proposta por Harry Markowitz, que considera pesos contínuos e otimiza o *trade-off* entre retorno e risco.

Adicionalmente, foi investigada uma abordagem intermediária por meio do ***Pauli Correlator Encoding* (PCE)**, que utiliza o estado quântico para extrair pesos contínuos, aproximando a solução quântica da formulação clássica e permitindo uma comparação mais direta entre os métodos. No caso binário, os ativos foram representados por um qubit cada. No caso contínuo, cada ativo foi representado por uma *Pauli String* (via PCE).

A justificativa para a escolha desse problema apoia-se em três pilares:

1. **Relevância:** É um problema amplamente estudado e estabelecido na literatura financeira.
2. **Praticidade:** Apresenta facilidade de representação matemática como um problema QUBO, o qual é nativamente suportado por algoritmos quânticos variacionais.
3. **Escalabilidade Restrita:** Sendo simples de reproduzir e de baixa dimensionalidade, atende às limitações de *hardware* (regime NISQ) do projeto.

Para resolver o problema QUBO formulado, a solução proposta utiliza o VQE. O VQE é um algoritmo híbrido clássico-quântico projetado especificamente para atuar de forma robusta em computadores quânticos de curto prazo (NISQ).

O funcionamento da solução divide-se em:

- **Mapeamento:** O problema QUBO é convertido em um Hamiltoniano de Ising, no qual o estado de menor energia corresponde ao portfólio ótimo;
- **Ansatz (Preparação do Estado):** Utiliza-se um circuito quântico parametrizado (Ansatz `TwoLocal`) para criar uma superposição de diferentes combinações de ativos;
- **Medição e Otimização:** O simulador quântico (`Statevector`) mede o valor esperado da energia. Em seguida, um otimizador clássico (SPSA) processa esse valor e atualiza os parâmetros do circuito para a próxima iteração, repetindo o ciclo até a convergência para a energia mínima (a combinação ótima de ações).

2. DESCRIÇÃO DOS DADOS, EXPERIMENTOS E RESULTADOS INICIAIS

A base de dados foi construída acessando séries históricas reais de preços ajustados diários através da biblioteca Python `yfinance`. O horizonte de tempo analisado cobriu um período de 5 anos, de Janeiro de 2021 a Janeiro de 2026.

Foram selecionados inicialmente 10 ativos de peso do índice S&P 500, distribuídos em setores distintos para testar a diversificação: Tecnologia (AAPL, MSFT), Financeiro (JPM), Energia (XOM), Saúde (JNJ), Varejo (WMT), Consumo (TSLA, AMZN) e Comunicação (META, GOOGL). A partir da variação percentual diária destes preços, foram extraídos os dois parâmetros cruciais para a otimização:

- **Retorno Esperado (μ):** A média anualizada dos retornos dos ativos.
- **Matriz de Covariância (Σ):** As métricas que capturam o risco individual e as dependências (correlações) entre pares de ativos ao longo do tempo. Utilizamos o método **Ledoit-Wolf**, que busca reduzir ruídos dos dados.
- **Risco Esperado:** O risco numérico, calculado por meio do método ***Correlated Value at Risk***, que mede, além da correlação, o potencial de perda máxima com uma confiança de 95% em uma distribuição normal.

Para que o desempenho do modelo quântico pudesse ser validado rigorosamente, uma forte etapa exploratória e a criação de *baselines* clássicos foram executadas:

1. ***Benchmarks* Clássicos:** O problema foi primeiro resolvido no domínio contínuo usando Simulações de Monte Carlo com dezenas de milhares de portfólios aleatórios, delineando a **Fronteira Eficiente de Markowitz**. Além disso, o portfólio quântico foi comparado ao retorno geral do S&P 500 no período.
2. **Execução do VQE:** Os parâmetros μ e Σ foram alimentados no `MinimumEigenOptimizer` do *framework* `Qiskit`, rodando no simulador para identificar a string binária ótima de ativos.

Os experimentos via computação quântica demonstraram resultados expressivos (**Tabela 1**):

- **Ativos Selecionados:** O VQE selecionou um portfólio enxuto, sugerindo a compra apenas das ações **GOOGL, WMT, XOM e JPM**.
- **Retorno Superior:** O portfólio quanticamente otimizado obteve uma taxa de retorno consideravelmente superior, entregando **193%** do rendimento total do *benchmark* de mercado (*S&P 500*).
- **Risco e Eficiência:** Impressionantemente, esse alto retorno foi alcançado com um nível de volatilidade menor que o do mercado (risco de **0.0234** contra 0.0247 do *S&P 500*). O escore retorno/risco confirmou o excelente *trade-off,* com a carteira VQE batendo o mercado num score de 11.178 *vs.* 5.582.

Tabela 1 - Resultados comparativos entre os métodos VQE, PCE e clássico do S&P 500.

Métrica	VQE (Binário)	Modelo Quântico Contínuo (PCE)	S&P 500 (Benchmark)
Retorno Relativo	**193% do *benchmark***	Superior ao *benchmark*	Base (100%)
Risco (Volatilidade)	**0.0234**	0.0294	0.0247
***Score* Retorno/Risco**	**11.178**	8.422	5.582
Desempenho Geral	Melhor resultado	Bom, mas inferior ao VQE	Referência
Interpretação	Alto retorno com menor risco	Promissor, mas ainda instável	Mercado

Já o modelo quântico contínuo obteve um escore retorno/risco de **8.422** e um risco de **0.0294**. Embora esse desempenho tenha sido ligeiramente inferior tanto ao modelo quântico binário quanto ao benchmark clássico de Monte Carlo, a técnica demonstrou ser capaz de derrotar o mercado (escore superior ao *S&P 500*). O resultado sugere que, apesar de promissora, a codificação contínua

via correlação de Pauli ainda requer ajustes na profundidade do circuito e na não-linearidade dos dados para superar a eficiência das outras soluções.

3. CONSIDERAÇÕES FINAIS

Os resultados atestam fortemente a viabilidade e o potencial dos algoritmos híbridos de computação quântica na esfera das finanças. A minimização da função objetivo (com energia de convergência bem-sucedida, registrando valores negativos para o Hamiltoniano) provou que o algoritmo explorou de forma eficaz o vasto espaço de busca combinatória. A carteira selecionada via VQE demonstrou maximização nítida de retorno alinhada à contenção de riscos, superando o índice geral da economia. A abordagem comprova que, com modelagens robustas, a teoria da diversificação combinada à otimização matemática é traduzível eficientemente para o espaço dos qubits

Com o alicerce estabelecido neste projeto, as futuras vias de aprofundamento envolvem:

- **Evoluir modelo contínuo:** Melhorar a implementação do *Pauli Correlator Encoding* para que ele obtenha um escore maior ou mais próximo do modelo de Markowitz clássico;
- **Restrições Realistas:** Introduzir fricções do mundo real na função QUBO, como impostos, custos de transação ou limite de exposição setorial;
- **Hardwares Reais:** Transportar a rotina testada nos simuladores (`Statevector`) para processadores quânticos físicos (QPU), mitigando o ruído intrínseco aos sistemas com estratégias avançadas de tratamento de erro (*Error Mitigation*). Isso pode ser feito por meio de uma API da IBM, por exemplo;
- **Escalabilidade Dimensional:** Expandir gradualmente o universo de ativos selecionáveis (ex: para 50 ou 100 ativos) para mensurar o limite computacional do modelo, bem como explorar estruturas de mercado de outros países.

4. REFERÊNCIAS BIBLIOGRÁFICAS
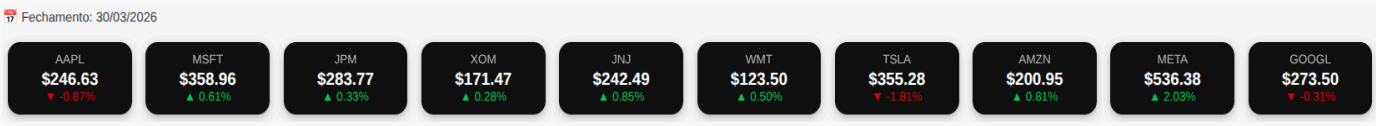
1. IBM QUANTUM. Qiskit Finance: Portfolio Optimization. 2023. Disponível em: <https://qiskit-community.github.io/qiskit-finance/>. Acesso em: 22 mar. 2026.
2. MARKOWITZ, H. Portfolio selection. The Journal of Finance, v. 7, n. 1, p. 77–91, 1952.
3. FARHI, E.; GOLDSTONE, J.; GUTMANN, S.. A quantum approximate optimization algorithm. 2014. Disponível em: <https://arxiv.org/abs/1411.4028>. Acesso em: 23 mar. 2026.
4. PERUZZO, A. et al. A variational eigenvalue solver on a photonic quantum processor. Nature Communications, v. 5, p. 4213, 2014.
5. WOERNER, S.; EGGER, J. Quantum risk analysis. Quantum Information, v. 5, n. 1, p. 15, 2019.
6. GLOVER, F.; KOCHENBERGER, G.; DU, Y. A tutorial on formulating and using QUBO models. 2018. Disponível em: <https://arxiv.org/abs/1811.11538>. Acesso em: 22 mar. 2026.
7. VENTURELLI, D.; KONDRATYEV, A.; KORENKEVYCH, D.. Quantum optimization of fully connected spin glasses. Physical Review Applied, v. 11, n. 3, p. 034040, 2019.
8. SCIORILLI, M. et al. Towards large-scale quantum optimization solvers with few qubits. Nature Communications, v. 16, n. 1, p. 476, 2025. Disponível em: <https://www.nature.com/articles/s41467-024-55346-z>. Acesso em: 26 mar. 2026.